

文章编号:1672-4747(2025)02-0014-18

基于强化学习的城市低空无人机路径规划

丁杰,王迪*

(济南大学,土木建筑学院,济南 250022)

摘要:【背景】随着低空经济的发展,低空空域正逐步成为城市交通变革的重要领域。无人机等新型交通工具在城市空间中的应用愈发广泛,但面临着路径规划、动态避障及多机协同等挑战。【目标】优化无人机路径规划算法,以增强无人机在低空复杂环境中的路径规划与避障能力、确保多无人机协同作业的高效性和安全性。【方法】引入 N 步更新策略与改进后的优先经验回放机制,提出一种基于强化学习的NP-MTDDQN算法。基于山东省济南市市中区的风流数据,构建包含多样建筑物和动态障碍物的三维低空环境,进行模拟实验以验证算法的有效性。【结果】三组对照实验表明,NP-MTDDQN算法在不同建筑物密度、不同优先级建筑物分布以及包含不同动态障碍物的复杂环境中,均能找到最优路径、区分建筑物优先级、识别并躲避动态障碍物,从而实现多无人机的协同作业。与传统的DQN和DDQN算法相比,该算法在路径规划的效率与准确性方面均有提升。【结论】NP-MTDDQN算法为低空智能交通网络中多无人机的路径规划问题提供了新的解决方案,有望提升城市空中交通的管理效率和响应速度。

关键词:智能交通;路径规划;无人机;深度强化学习;低空经济

中图分类号:TU984.191;TP18 **文献标志码:**A **DOI:**10.19961/j.cnki.1672-4747.2024.12.007

Urban low-altitude UAV path planning based on reinforcement learning

DING Jie, WANG Di*

(School of Civil Engineering and Architecture, University of Jinan, Jinan 250022, China)

Abstract: 【Background】 Owing to the emergence of low-altitude economies, low-altitude airspace has become increasingly pivotal for the revolution of urban transportation. Unmanned aerial vehicles (UAVs) and other novel transportation modes are being used increasingly in urban spaces; however, they are affected by challenges such as path planning, dynamic obstacle avoidance, and multi-UAV coordination. 【Objective】 To optimize UAV path-planning algorithms, enhance the path-planning and obstacle-avoidance capabilities of UAVs in complex low-altitude environments, and ensure the efficiency and safety of multi-UAV collaborative operations. 【Methods】 An NP-MTDDQN algorithm based on reinforcement learning, which incorporates an N -step update strategy and an improved prioritized experience replay mechanism, is proposed. A three-dimensional low-altitude environment featuring diverse buildings and dynamic obstacles is constructed using wind-flow data from Shizhong District, Jinan City, Shandong Province, to conduct simulation experiments and validate the effectiveness of the algorithm. 【Results】 Three sets of controlled experiments indicate that the NP-

收稿日期:2024-12-07

录用日期:2024-12-30

网络首发:2025-01-02

审稿日期:2024-12-07~2024-12-15; 2024-12-28~2024-12-30

基金项目:山东省自然科学基金项目(ZR2024QG174);山东省城市更新学会重点研究专项项目(SURS240603)

作者简介:丁杰(1999—),男,硕士研究生,研究方向为智能交通、深度学习,E-mail: dingjie@stu.ujn.edu.cn

通信作者:王迪(1991—),男,博士,讲师(校聘教授),硕导,研究方向为交通大数据分析、交通系统规划,E-mail: cca_wangd@ujn.edu.cn

引文格式:丁杰,王迪. 基于强化学习的城市低空无人机路径规划[J]. 交通运输工程与信息学报, 2025, 23(2): 189-206.

DING Jie, WANG Di. Urban low-altitude UAV path planning based on reinforcement learning[J]. Journal of Transportation Engineering and Information, 2025, 23(2): 189-206.

MTDDQN algorithm can identify optimal paths, distinguish building priorities, as well as identify and avoid dynamic obstacles in complex environments with varying building densities, different priority building distributions, and dynamic obstacles, thereby facilitating multi-UAV collaboration. Compared with the conventional DQN and DDQN algorithms, the NP-MTDDQN algorithm exhibits improved efficiency and accuracy in path planning. **[Conclusions]** The NP-MTDDQN algorithm provides a novel solution to the path-planning problem for multi-UAVs in low-altitude intelligent transportation networks, thus potentially enhancing the management efficiency and response speed of urban air traffic.

Key words: intelligent transportation; path planning; unmanned aerial vehicles; deep reinforcement learning; low-altitude economy

0 引言

在全球经济迅猛发展的大背景下,低空经济作为一种崭新的经济形态,正逐步成为引领城市交通变革的重要驱动力^[1]。低空空间也从传统空域管理的边缘区域,蜕变为一个充满开发潜力的交通网络新平台。随着无人机、空中出租车等新型交通工具在低空空域的广泛应用^[2-3],各国正不断加大对低空基础设施的投资力度^[4-6],旨在确保低空交通的安全、高效运行。在此背景下,如何构建科学、智能的低空交通网络,已成为热点的研究议题^[7-8]。

低空智能交通网络是低空经济的重要组成部分^[9],不仅意味着交通方式的升级,更代表了城市交通管理模式智能化转型。与传统交通网络不同,低空智能交通网络具有更高的灵活性和时效性,特别是在应急救援、物流配送^[10]、城市巡查等领域具有广阔的应用前景。此外,低空智能交通网络打破了传统单一层次的交通体系,未来的交通规划不仅需要考虑地面与地下空间的交通需求,还需要为低空交通预留合理的空间,形成多层次、立体化的交通网络体系^[11],如在合适的位置规划并建设无人机起降点^[12]、空中走廊等关键基础设施。此外,在物流配送领域,无人机物流的高效性使得传统物流配送中心的布局发生显著变化^[13-14],原本需要依赖地面交通的物流中心,可以通过低空交通覆盖更大范围,从而优化城市的物流网络布局,减少交通拥堵的同时提高配送效率。在土地利用方式上,需要增加服务低空交通的基础设施^[15-16];在交通空间管理方面,为保障低空空间的安全与高效利用,需要制定并完善空域使用规则^[17-19],建立智能化的空域管理平台^[20],对无人机的飞行高度、路线等进行实时监控。然而,当前低空智能交

通网络的构建仍面临着诸多挑战。以无人机为例,如何突破技术瓶颈、优化空中管制并提升公众认可度^[21],在有限的空域内合理规划飞行路径,确保其在复杂多变的低空环境中实现自主避障与安全飞行,并在多无人机协同作业的情况下提高整体运行效率,这些问题都亟待解决。

为加速构建低空无人机智能交通网络,本文提出了一种基于强化学习的路径规划算法来训练无人机,在低空环境中实现了多无人机路径规划和自主避障。对照实验中,智能体在包含不同障碍物的低空环境下均能找到最优路径。在具有不同优先级障碍物的环境下,智能体能够避开高优先级障碍物,实现障碍物的优先级区分。在具有动态障碍物的环境下,智能体能够成功避开动态障碍物到达最终目标点,并且在动态的低空环境中表现稳定。实验结果表明,该算法可以在低空空域中实现多无人机协同作业、寻找到达目标点的最优路径。

本文的贡献总结如下:(1)提出了多目标协同下 N 步更新与改进后的优先经验回放机制的 Double DQN 算法(即 NP-MTDDQN 算法),并在具有不同障碍物的低空环境中进行了实验。结果表明,智能体能够自主避障并成功找到到达目标点的最优路径。(2)利用山东省济南市市中区的风流数据建立了 $2\text{ km}\times 2\text{ km}\times 0.1\text{ km}$ 的三维低空环境,为算法提供了符合实际应用场景的环境支持。

1 文献综述

近年来,依托于低空经济,无人机在各大领域中的应用逐渐增加,无人机行业的核心竞争力与日俱增^[22]。无人机运行最重要的前提便是实现自主决策,并在有限的范围内寻找到达目标点的无

障碍最优路径,本质上是一个路径规划问题。对于路径规划,目前常用的解决方案主要有三大类:传统算法、智能仿生算法和深度强化学习算法。常用的传统算法主要有Dijkstra算法、A*算法、人工势场(Artificial Potential Field, APF)算法、快速搜索随机树(Rapid-exploring Random Trees, RRT)算法等。Dijkstra算法虽然可以找到最短路径,但该算法只能解决单源最短路径问题,且不能处理存在负权边的情况^[23];A*算法是静态路网中求解最短路径的最有效搜索方法,但该算法并不适用于动态环境,且在高维空间中的计算量较大^[24];APF算法规划出来的路径一般是平滑且安全的,但是存在着局部最优的问题,且无法在具有复杂障碍物的环境中寻找到路径^[25];RRT算法通过不断生成随机扩展树来规划可行路径,但由于算法的随机抽样,规划的路径可能不是最优路径^[26]。总之,传统的路径规划算法都具有一定的局限性,且在动态环境下的性能无法保证。

为了克服传统算法的局限性,研究者们开始探索智能仿生和深度强化学习等路径规划的新方法。目前常用的智能仿生路径规划算法有神经网络算法、蚁群算法、遗传算法等;神经网络算法是一类受人脑神经网络结构和功能启发的算法,通过网络的自学习来规划最优路径,但模型的性能高度依赖于训练数据的分布,若测试数据与训练数据分布不一致,则模型性能可能会下降^[27];蚁群算法是一种模拟蚂蚁寻找食物路径行为的启发式搜索算法,该算法采用正反馈机制,规划的路径能够逼近最优解,但由于搜索的随机性和盲目性,易导致搜索时间长、搜索速度慢,且容易陷入局部最优等问题^[28];遗传算法是一种通过模拟自然进化过程来搜索最优解的方法,能在搜索过程中自动获取和积累有关搜索空间的知识,并自适应地控制搜索过程以求得最佳解,但该算法计算速度不快,占用大量存储空间和计算时间^[29]。这些智能仿生路径规划算法的共同缺陷是需要大量的人类经验或者训练集,在未知环境中的应用难以预测,或者需要耗费大量时间进行推理,无法满足实时性的需求。

尽管传统算法和智能仿生算法为无人机路径规划提供了一定的解决方案,但在低空环境中,无人机的应用场景更加复杂,路径规划面临着更大的挑战。无人机不仅需要考虑常规的地面障碍

物,还需要应对建筑物之间的复杂间距等威胁。同时,城市环境的动态变化性,例如风速的影响,进一步增加了无人机路径规划的难度。此外,无人机的协同作业也是城市低空智能交通网络发展的关键环节。在低空环境中,多个无人机需要共享空域资源,协调行动。深度强化学习通过与环境的交互进行学习,无需人工设计或推理,能够自主解决路径规划问题^[30],为无人机在低空环境中的运行提供充分保障。近年来,基于强化学习的路径规划研究逐渐增多。如Yan等^[31]提出了一种基于全局态势信息的深度强化学习方法,该方法将 ϵ -greedy与启发式搜索规则相结合,通过Dueling Double Deep Q-networks算法来选择动作,解决了无人机全局路径规划问题;Yan等^[32]将Double DQN和长短期记忆网络进行结合,来增强水上无人车对于环境的记忆能力;Yang等^[33]提出了一种改进的DQN算法,通过引入先验知识和先验规则来提高算法的收敛速度,解决了传统路径规划中收敛速度慢和随机性过大的问题;Han等^[34]提出了一种增强的Double DQN路径规划方法,通过构建双分支网络结构以区分处理导航与避障任务,并引入专家经验模块来减少无效探索,显著提升了路径规划的效率和准确性;Deguale等^[35]提出了一种PMR-Dueling DQN算法,通过结合深度强化学习中的Dueling网络结构、优先级经验回放以及形状化奖励机制,显著提升了复杂环境中路径规划的稳定性;Kong等^[36]提出了一种B-APFDQN算法,通过引入APF算法作为动作选择的辅助,结合 ϵ -greedy策略,有效提升了DQN的收敛速度和路径规划的效率;Huang等^[37]设计了一种带权重的奖励函数,并在DQN和Dueling DQN算法上进行验证,解决了动态障碍物和机器人之间相对运动导致的异常奖励问题。

尽管上述研究在单一目标的路径规划问题上取得了显著成果,但对多无人机协同作业中的多目标优化问题探讨仍显不足。随着城市低空智能交通网络的不断发展,设计高效的多目标协同算法,以实现多无人机在复杂动态环境中的资源共享和路径协同,已成为当前研究的重点方向。Shen等^[38]提出了一种基于非支配排序的定向进化多目标蜣螂优化器,通过集成方向进化策略和自适应随机排名机制,解决了多无人机协同路径规划的问题;凌帅等^[39]基于协同进化思想提出了一种

多目标协同优化的遗传算法,通过引入选择算子、协同交叉算子和差分变异算子来增强算法的收敛性;Zhang 等^[40]提出了一种基于强化学习的多模式协同多目标粒子群优化算法,通过强化学习选择适合的位置更新策略,实现了探索、开发和混合更新模式的平衡;王娜等^[41]提出了一种基于多智能体深度强化学习的无人机协作规划方法,通过构建基于任务分配的智能体任务规划器和深度强化学习方法,实现了群体行为的优化和协同控制;张子贤等^[42]采用元强化学习方法建立元模型,通过结合元学习 Reptile 算法思想与滚动基线方法,提高了不同子任务的适应性和计算中的灵活性;Chen 等^[43]提出了一种基于多智能体强化学习的路径规划算法,采用集中式训练和分散式执行架构来协调所有无人机,并引入循环神经网络的隐藏状态,利用历史观察信息在未知环境中实现了多无人机协同自主路径规划。

以上研究为无人机路径规划提供了诸多解决思路,但相对欠缺的是在动态低空环境中多无人机协同下的路径规划研究。因此,本文构建了基于强化学习的无人机路径规划算法,针对低空智能交通网络中多无人机的协同问题,引入 N 步更新和改进后的优先经验回放机制,提升了无人机在低空环境中的自主避障和路径规划能力。该算法不仅能够动态环境下自主学习和决策,还能够复杂多变的空域中实现全局最优路径规划,保证了无人机在低空环境中的安全高效运行。

2 动力学模型

为了准确地计算和控制无人机的路径,建立了基于无人机的动力学模型,如图 1 所示。




图 1 全局坐标系和 UAV 坐标系

Fig.1 Global coordinate system and UAV coordinate system

通过建立全局坐标系和 UAV 坐标系来描述 UAV 的运动和受力。基于全局坐标系的 UAV 位姿表示为

$$\mathbf{H} = [\xi \quad \eta \quad \zeta \quad \phi \quad \theta \quad \psi] \quad (1)$$

基于 UAV 坐标系的速度和力分别表示为

$$\mathbf{V} = [u \quad v \quad w \quad p \quad q \quad r]^T \quad (2)$$

$$\boldsymbol{\tau} = [X \quad Y \quad Z \quad K \quad M \quad N]^T \quad (3)$$

通常, UAV 直接读取的运动数据是基于 UAV 坐标系的,因此,需要通过欧拉角转换获得全局坐标系下的运动数据,两者之间的转换方程可以表示为

$$\mathbf{J}(\mathbf{H}) = \begin{bmatrix} c\psi c\theta & s\psi s\theta c\phi - s\psi c\phi & s\psi s\theta s\phi + c\psi s\phi & 0 & 0 & 0 \\ s\psi c\theta & c\psi s\theta c\phi + s\psi s\phi & c\psi s\theta s\phi - s\psi c\phi & 0 & 0 & 0 \\ -s\theta & c\theta s\phi & c\theta c\phi & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & c\phi & -s\phi \\ 0 & 0 & 0 & 0 & s\phi & c\phi \end{bmatrix} \quad (4)$$

式中: c 表示 $\cos$, s 表示 $\sin$, 则全局坐标系下的速度 $\dot{\mathbf{H}}$ 可表示为

$$\dot{\mathbf{H}} = \mathbf{J}(\mathbf{H}) \cdot \mathbf{V} \quad (5)$$

即:

$$\begin{bmatrix} \dot{x} \\ \dot{y} \\ \dot{z} \\ \dot{\psi} \\ \dot{\theta} \\ \dot{\phi} \end{bmatrix} = \begin{bmatrix} c\psi c\theta & s\psi s\theta c\phi - s\psi c\phi & s\psi s\theta s\phi + c\psi s\phi & 0 & 0 & 0 \\ s\psi c\theta & c\psi s\theta c\phi + s\psi s\phi & c\psi s\theta s\phi - s\psi c\phi & 0 & 0 & 0 \\ -s\theta & c\theta s\phi & c\theta c\phi & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & c\phi & -s\phi \\ 0 & 0 & 0 & 0 & s\phi & c\phi \end{bmatrix} \cdot \begin{bmatrix} u \\ v \\ w \\ p \\ q \\ r \end{bmatrix} \quad (6)$$

本文采用六自由度动力学模型研究 UAV 的运动,动力学方程表示为

$$\mathbf{M}(q)\ddot{q} + \mathbf{C}(q, \dot{q})\dot{q} + \mathbf{g}(q) = \boldsymbol{\tau} \quad (7)$$

式中: $\mathbf{M}(q)$ 是一个质量矩阵; $\mathbf{C}(q, \dot{q})$ 表示离心力矩阵和科氏力; $\mathbf{g}(q)$ 是重力向量; $\boldsymbol{\tau}$ 是关节扭矩向量。

3 算法

3.1 强化学习

本文将强化学习应用于无人机路径规划中的避障决策。在每一个时间步,智能体选择一个动作使环境状态发生变化,环境返回智能体的下一个状态和奖励,智能体根据这些反馈选择下一个动作。在强化学习中,所有状态的集合记为状态空间 S ,所有动作的集合记为动作空间 A 。在每个时间步 t ,环境的状态记为 S_t ,智能体选择动作记为 A_t ,环境给出下一个状态记为 S_{t+1} ,下一个奖励记为 R_{t+1} ,折扣因子记为 γ_{t+1} ($\gamma \in [0, 1]$)。每个状态下动作的概率分布为策略 π ,智能体通过策略选择动作。 $\pi(a|s)$ 表示在状态 s 下选择动作 a 的概率,传递函数 $p(s'|s, a)$ 表示在状态 s 下选择动作 a 的条件下获得下一个状态 s' 的概率, $r(s, a)$ 表示在状态 s 下选择动作 a 的奖励。其即时奖励表达为

$$r_t = r(s_t, a_t) \quad (8)$$

式中: r_t 是在时间步 t 智能体采取动作 a_t 后从环境中获得的即时奖励; s_t 是该时间步的状态。

累计奖励表达为

$$R_t = \sum_{k=t}^T \gamma^{k-t} r_k \quad (9)$$

式中: R_t 是从时间步 t 开始到终止时间 T 的累计奖励; γ 是折扣因子。

期望累计奖励表达为

$$\begin{aligned} G_t = E[R_t] = & R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \\ & \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \end{aligned} \quad (10)$$

式中: G_t 是从时间步 t 开始的长期累计奖励; R_{t+k+1} 是在时间步 $t+k+1$ 获得的即时奖励; k 是从时间

步 t 开始的步数索引。

强化学习的价值估计是评估智能体在特定策略下从某个状态或采取某个动作开始所能获得的长期累计奖励,包括状态价值函数和动作价值函数。状态价值函数 $V^\pi(s)$ 表示从状态 s 开始并遵循策略 π 所能获得的期望累计奖励,表示为

$$\begin{aligned} V^\pi(s) = E[G_t | s_t = s, \pi] = & E \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \middle| s_t = s \right] = \sum_{a \in A} \pi(a|s) \\ & \sum_{s', r} p(s', r | s, a) [r + \gamma V^\pi(s')] \end{aligned} \quad (11)$$

动作价值函数 $Q^\pi(s, a)$ 表示在策略 π 下,从状态 s 开始并采取动作 a 所能获得的期望累计奖励,提供了在特定状态下采取特定动作的期望回报,表示为

$$\begin{aligned} Q^\pi(s, a) = E[G_t | s_t = s, a_t = a, \pi] = & E \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \middle| s_t = s, a_t = a \right] = \\ & \sum_{s', r} p(s', r | s, a) \left[r + \gamma \sum_{a' \in A} \pi(a' | s') Q^\pi(s', a') \right] \end{aligned} \quad (12)$$

动作价值函数与状态价值函数之间的关系可表示为

$$V^\pi(s) = \sum_{a \in A} \pi(a|s) Q^\pi(s, a) \quad (13)$$

状态价值 $V^\pi(s)$ 可以看作是在状态 s 下,按照策略 π 选择每个可能动作 a 的动作价值 $Q^\pi(s, a)$ 的加权和,即状态价值是所有可能动作的期望价值。

最优策略 $\pi^*(s)$ 是选择在每个状态 s 下使行动值最大化的行动,表示为:

$$\begin{aligned} \pi^*(s) = \arg \max_{\pi} v_{\pi}(s) = & \arg \max_{\pi} q_{\pi}(s, a) \end{aligned} \quad (14)$$

最优状态值和最优动作值可表示为

$$\begin{aligned} V_*(s) = \max_{a \in A(s)} & (r(s, a) + \\ & \gamma \sum_{s' \in S} P(s' | s, a) V_*(s')) \end{aligned} \quad (15)$$

$$\begin{aligned} Q_*(s, a) = r(s, a) + & \gamma \sum_{s' \in S} P(s' | s, a) \max_{a' \in A(s')} Q_*(s', a') \end{aligned} \quad (16)$$

式中: $A(s)$ 是在状态 s 下所有可能的动作集合;

$r(s, a)$ 是在状态 s 下采取动作 a 获得的即时奖励;
 $P(s'|s, a)$ 是从状态 s 采取动作 a 转移到状态 s' 的概率。

基于以上步骤,强化学习的最终目标可以转化为求解最优状态值 $V_*(s)$ 和最优动作值 $Q_*(s, a)$ 。

3.2 改进后的优先经验回放机制

经验回放是将每一次智能体选择的一个动作与环境交互的数据储存到创建的经验池中,并在训练过程中按照一定的规则从储存的经验中采样,然后利用采样经验来更新网络。优先经验回放(Prioritized Experience Replay, PER)是一种强化学习中优化经验采样策略的机制,与均匀采样相比,PER 机制将时序误差(Temporal Difference-error, TD-error)作为衡量标准评估被采样数据的优先级。TD-error 指当前 Q 值和目标 Q 值的差值,误差越大表示该数据对网络参数的更新越有帮助。因此,样本的 TD-error 绝对值越大,对学习的引导作用就越大,越容易被采样。在此基础上,PER 机制可以加快网络的收敛速度。

Sum Tree 是一种特殊的二叉树数据结构,常用于 PER 机制中的经验采样。在 Sum Tree 中,所有的经验样本储存在底部子节点上,每个节点一个样本,且保存有样本的优先级 p 。父节点不保存样本数据,只保存子节点的优先级之和。如果经验样本的优先级发生变化,从对应的叶子节点开始更新,修改节点值并向上更新所有父节点的值。Sum Tree 的根节点是所有 p 的和。对于每个经验 i ,其采样概率 p_i 可以通过以下公式计算

$$p_i = \frac{w_i}{W} \quad (17)$$

式中: w_i 是经验 i 的优先级权重; W 是所有经验权重的总和。

为了调整采样过程中的偏差,需要计算每个采样经验的重要性,即采样权重,可通过以下公式计算

$$\hat{w}_i = \frac{1}{n} \cdot \frac{p_i}{p_i + \varepsilon} \quad (18)$$

式中: n 是批次大小; ε 是一个小的常数,用于保证除数不为零。

基于以上步骤,考虑样本优先级的损失函数可以表达为

$$\begin{aligned} Loss(\theta) = & \frac{1}{n} \sum_{i=1}^n w_i (y_i - Q(s_i, a_i; \theta))^2 = \\ & \frac{1}{n} \sum_{i=1}^n w_i (r_i + \gamma Q_{\text{target}}(s_{i+1}, \arg\max_{a'} Q_{\text{online}}(s_{i+1}, a'; \theta); \theta_{\text{target}}) - \\ & Q(s_i, a_i; \theta))^2 \end{aligned} \quad (19)$$

式中: w_i 是经验 i 的优先级权重,由 TD-error 进行归一化。

标准 PER 机制的核心思想是加速收敛,通过 TD-error 来衡量经验的重要性,从而对采样概率进行调整。但其忽略了经验数据分布的特性,在动态低空环境中容易因积极经验比例过低而导致经验池的不平衡,进而影响智能体的学习效果。本文提出了一种改进后的 PER 机制,对智能体探索的积极经验进行筛选,然后将这些积极经验储存在经验缓冲区中,以备后续经验回放。通过增强积极经验来改进经验缓冲区,提高积极经验的数量及其利用率。改进后的 PER 机制能够动态调整积极经验的比例,显著提升积极经验的利用率,提高算法在动态低空环境中的性能。

路径规划的最终目标是躲避障碍物到达目标点,因此所能到达目标点的经验就是积极经验。将积极经验的个数记为 E_{positive} ,总经验的个数记为 E_{total} ,则积极经验与其他经验的比值为

$$M = \frac{E_{\text{positive}}}{E_{\text{total}} - E_{\text{positive}}} \quad (20)$$

动态低空环境中,智能体与障碍物的随机交互会导致经验池中积极经验与消极经验的比例严重失衡。这种失衡直接影响了智能体的学习方向,使其更倾向于重复采样大量的消极经验,而对积极经验利用不足。改进后的 PER 机制不仅保留了标准 PER 机制基于 TD-error 进行采样的核心思想,同时通过筛选积极经验并扩展其数量,在经验池中动态调整积极经验和消极经验的比例,使积极经验占比从实际比例 M 动态提升至理想比例 αM ($\alpha > 1$),即

$$P = \alpha M \quad (21)$$

式中: α 为积极经验的扩展比例。

进一步将积极经验的数量扩展至 E'_{positive} ,即

$$E'_{\text{positive}} = P(E_{\text{total}} - E_{\text{positive}}) \quad (22)$$

改进后的PER机制在多个方面优于标准PER机制,如表1、图2所示。在经验优先级评估上,标准PER机制仅依赖TD-error计算样本优先级,而改进后的PER机制引入了对积极经验的筛选与扩展,进一步提升了对关键经验的关注度。在解决经验不平衡问题方面,标准PER机制缺乏明确的处理方案,而改进后的PER机制通过筛选并动态扩展积极经验,有效平衡了积极经验与消极经验的比例,缓解了动态环境中的经验偏差问题。在收敛速度上,标准PER机制会因为采样到大量无效数据而导致收敛较慢,而改进后的PER机制聚焦关键经验,加速了智能体的学习过程。对于噪

声的鲁棒性,标准PER机制容易受到高TD-error的噪声数据干扰,而改进后的PER机制通过增强积极经验比例,减少了噪声数据对学习的负面影响。在动态适应能力方面,标准PER机制不具备动态调整的能力,而改进后的PER机制能够根据智能体的学习进度和环境变化实时优化积极经验的比例,提升了其适应动态任务的能力。最后,在算法稳定性上,标准PER机制会在动态环境中表现出一定的性能波动,而改进后的PER机制通过优化经验分布显著提高了学习过程的稳定性,更适合复杂环境下的强化学习任务。

表1 标准PER机制与改进后的PER机制对比

Tab.1 Comparison between standard and improved PER mechanism

指 标	标准PER机制	改进后的PER机制
经验优先级评估	仅基于TD-error	基于TD-error、筛选和扩展积极经验
解决经验不平衡	无明确处理	筛选并动态扩展积极经验,平衡经验比例
收敛速度	较慢,可能浪费大量训练步数	更快,聚焦关键经验
对噪声的鲁棒性	容易受到噪声数据干扰	增强积极经验比例,减少噪声干扰
动态适应能力	无动态调整能力	根据学习进度和环境动态调整积极经验比例
算法稳定性	在动态环境中性能波动较大	稳定性显著提高




图2 标准PER机制与改进后的PER机制累计奖励对比

Fig.2 Comparison of cumulative rewards between standard and improved PER mechanism

3.3 N -step Priority-Multiple Target DDQN(NP-MTDDQN)算法

在低空环境中,许多实际问题的状态和动作空间是连续且高维的,导致强化学习难以适用。因此,引入了深度神经网络来处理城市空间中复杂的环境,称为深度强化学习。深度Q网络(Deep Q Network, DQN)是典型的深度强化学习算法之一,在DQN中,优化目标是最小化损失函数,即逐步减小返回值和动作值的估计值之间的差距。在

DQN的训练过程中,使用同一个神经网络对 Q 值进行估计,导致估计的 Q 值偏高。Double DQN(DDQN)采用在线网络来选择动作,利用目标网络来估计回报值,以此来解决过高估计的问题。通过这种方式,DDQN分离了用于选择动作的在线网络和用于评估该动作 Q 值的目标网络,从而减少了估计的偏差,提高了学习过程的稳定性和性能。

前文提到的方法只考虑了一次更新,使用当前时间步 t 和下一个时间步长 $t+1$ 的信息,表示为

$$G_t = R_{t+1} + \gamma V_t(s_{t+1}) \quad (23)$$

为了加快学习的过程,采用 N 步更新方法,即后续进行多步的信息更新,回报方程表达为

$$G_t^{(N)} = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{N-2} R_{t+N-1} + \gamma^{N-1} V_{(s_{t+N})} \quad (24)$$

式中: $G_t^{(N)}$ 是从时间步 t 开始的 N 步回报; R_{t+k} 是在时间步 $t+k$ ($k=1,2,\dots,N-1$)获得的即时奖励; $V_{(s_{t+N})}$ 是在时间步 $t+N$ 下状态 s_{t+N} 的价值估计。

损失函数表达为

$$Loss(\theta) = E \left[w_i (R^{(N)} + \gamma^{(N)} \max_{a'} Q_{\text{target}}(s_{t+N}, a'; \theta_{\text{target}}) - Q(s_t, a_t; \theta))^2 \right] \quad (25)$$

式中: $Loss(\theta)$ 是损失函数; w_i 是优先级权重; $R^{(N)}$ 是从当前状态和动作开始的 N 步回报; $Q_{\text{target}}(s_{t+N}, a'; \theta_{\text{target}})$ 是目标网络对下一个状态 s_{t+N} 下所有可能动作 a' 的最大估计 Q 值; θ_{target} 是目标网络的参数。

考虑到多无人机的协同运行, 本文将多个无人机完成多个目标任务纳入到算法当中, 在此基础上寻求完成多目标任务所消耗的总时间达到最小。多无人机在同一空间中完成任务时会相互产生路径干扰, 因此, 在总耗时最小的目标下, 将路径干扰延误作为最终评定的因素之一。基于此, 所有无人机的联合状态 S 和联合动作 A 表达为

$$S = S_1 \times S_2 \times \cdots \times S_N \quad (26)$$

$$A = A_1 \times A_2 \times \cdots \times A_N \quad (27)$$

所有无人机完成任务的策略 $\pi(a|s)$ 表达为

$$\pi(a|s) = \prod_{i=1}^N \pi_i(a_i|s_i) \quad (28)$$

在此基础上, 定义协同奖励函数 $R_c(s, a)$, 并考虑完成任务总耗时最小以及相互之间的路径干扰延误最小, 此时协同奖励函数表达为

$$R_c(s, a) = \sum_{i=1}^N (-d_i(s_i, a_i) - I_i(s, a)) \quad (29)$$

式中: $d_i(s_i, a_i)$ 是无人机 i 完成任务所需的时间; $I_i(s, a)$ 是路径干扰项。

联合状态价值函数和联合动作价值函数表达为:

$$V^\pi(S) = E \left[\sum_{k=0}^{\infty} \gamma^k R_c(S_{t+k}, A_{t+k}) \mid S_t = S, \pi \right] \quad (30)$$

$$Q^\pi(S, A) =$$

$$E \left[\sum_{k=0}^{\infty} \gamma^k R_c(S_{t+k}, A_{t+k}) \mid S_t = S, A_t = A, \pi \right] \quad (31)$$

式中: S 是联合状态; A 是联合动作; $R_c(S_{t+k}, A_{t+k})$ 是在时间步 $t+k$ 的协同奖励函数。

则 N 步更新回报 $G^{(N)}$ 表达为

$$G^{(N)}(s_t, a_t) = \sum_{k=1}^N \gamma^{k-1} R_c(s_{t+k-1}, a_{t+k-1}) \quad (32)$$

此时联合损失函数 $Loss(\theta)$ 表达为

$$Loss(\theta) = E \left[(G^{(N)}(s_t, a_t) - V(s_t))^2 \right] \quad (33)$$

式中: $V(s_t)$ 是联合状态价值函数。

在考虑总耗时最少和路径干扰延误最小的情况下, 可将最终求解的目标表达为

$$\min_{\pi} \left(\sum_{i=1}^N [d_i(s_i, a_i)] + \sum_{i=1}^N E[I_i(s, a)] \right) \quad (34)$$

本文应用了上述提到的 NP-MTDDQN 算法, 该算法以无人机的空间位置信息、风流信息作为输入状态, 通过算法控制无人机的路径规划。算法框架和神经网络架构如图3、图4所示。




图3 算法框架

Fig.3 Algorithm framework




图4 神经网络架构

Fig.4 Neural network architecture

在NP-MTDDQN算法中,更新步数 N 以及改进后的PER机制中积极经验权重 α 的取值对于算法的性能具有决定性影响,其取值经过灵敏度分析和实验优化,如图5所示。更新步数 N 决定了更新目标中包含未来回报的数量,取值过小会导致算法对短期回报过于依赖,无法充分利用长期奖励信息;取值过大则会引入更多的累计估计误差,从而降低算法的稳定性和性能。改进后的PER机制中积极经验权重 α 控制了经验缓冲池中积极经验的占比,取值过小会导致采样过程无法有效聚焦于关键决策样本;取值过大则会导致采样过程高度依赖积极经验样本,丧失样本多样性并产生过拟合现象。实验测试了 N 和 α 的取值对于算法的影响,结果显示,当 $N=6, \alpha=2.0$ 时,算法能够在长期决策和误差累计之间达到最佳平衡,实现样本多样性和关键样本权重之间的平衡,确保算法的稳定性,避免误差累计和过拟合问题。




图5 超参数灵敏度分析

Fig.5 Sensitivity analysis of hyperparameters

4 实验

本文利用山东省济南市市中区的风流数据构

建了真实的低空环境,并进行了各种避障实验。如图6所示,三个坐标轴分别表示长度、宽度和高度,蓝色箭头表示该位置的风流方向,灰色体块代表城市中的建筑物,圆形标志代表起点,叉号标志代表终点,起点与终点的颜色相互对应。为了还原真实的城市低空环境,从风流数据中提取部分数据,等比例建立了 $2\text{ km} \times 2\text{ km} \times 0.1\text{ km}$ 的三维城市空间,并应用插值方法计算相邻两个数据点之间的风流。




图6 带有风场的城市空间可视化模型

Fig.6 Urban space visualization model with wind field

为了加强智能体的自主探索能力,使智能体尽可能地选择所有的动作,使用 ϵ -greedy策略以确保智能体能够充分探索状态空间。 ϵ -greedy是一种探索策略,智能体在少数情况下以概率 ϵ 选择一个随机行为,在大多数情况下以概率 $1 - \epsilon$ 选择当前已知的最佳行为。当 a 是随机选择时,则其概率为 $\epsilon/|A(s)|$;当 a 为最优行动时,则其概率为 $1 - \epsilon + \epsilon/|A(s)|$,这里 $1 - \epsilon$ 是选择最优行动的概率,而 $\epsilon/|A(s)|$ 是由于随机选择而选择到最优行动的概率;如果 a 不是最优行动也不是随机选择的行动,则 $\pi(a|s) = 0$,即不会选择这个动作。表示为

$$a = \operatorname{argmax} Q(s, a) \quad a \in A \quad (35)$$

$$\pi(a|s) = \begin{cases} \frac{\epsilon}{|A(s)|} & a \text{ 为随机选择} \\ 1 - \epsilon + \frac{\epsilon}{|A(s)|} & a \text{ 为最优行动} \\ 0 & \text{其他情况} \end{cases} \quad (36)$$

式中: $A(s)$ 是在状态 s 下所有可能发生的动作集

合; $|A(s)|$ 是该集合的大小, 即在状态 s 下可采取的行动数量。

在奖励函数方面, 将智能体移动的步数、与目标点的距离、与每个障碍物的距离、与障碍物的碰撞、风流方向与智能体动作的夹角、到达目标点纳入到奖励函数内。为了鼓励智能体尽可能向目标点移动, 将与目标点的距离缩小设置为较小的正奖励, 将步数增加设置为负奖励, 使智能体离目标点越近, 奖励越高, 步数越少, 奖励越高

$$R_1 = \beta_1 step + \beta_2 \|p_a - p_t\|_2 \quad (37)$$

式中: $step$ 表示智能体移动的参数; p_a 表示智能体在当前时间步的位置; p_t 表示目标点的位置; β_1 和 β_2 是平衡步长奖励和距离奖励的参数, 分别为 -0.01 和 -0.1 。

考虑到城市风流的影响, 沿着风流的方向移动会更快或者更省力, 因此, 将动作方向与风流方向之间的夹角纳入到奖励函数中。两者夹角越小, 余弦值越大, 奖励越高

$$R_2 = \cos(|\varphi - \varphi'|) \quad (38)$$

式中: φ 表示智能体的动作方向; φ' 表示风流方向。

为了提示智能体避开障碍物, 将与障碍物的碰撞设置为较大的负奖励, 将智能体与每个障碍物之间的距离设置为较小的正奖励, 鼓励智能体与障碍物之间保持一定的距离。智能体距离障碍物越近, 奖励越小。同时, 在 R_1 的约束下, 智能体不会表现出消极行为或保持静止

$$R_3 = \beta_3 \sum_i \|p_a - B_i\|_2 + \beta_4 building_reward \quad (39)$$

式中: B_i 表示第 i 个建筑物的位置; β_3 和 β_4 是平衡与建筑物距离奖励和碰撞奖励的参数, 分别为 0.001 和 10 。

$$building_reward = \begin{cases} -100 & \text{发生碰撞} \\ 0 & \text{不发生碰撞} \end{cases} \quad (40)$$

为了提示智能体避开其他的智能体从而减小路径干扰延误, 将与其他智能体的碰撞设置为较大的负奖励, 将智能体与其他智能体之间的距离设置为较小的正奖励, 鼓励智能体与其他智能体

之间保持一定的距离。智能体距离其他智能体越近, 奖励越小

$$R_4 = \beta_5 \sum_i \|p_a - C_i\|_2 + \beta_6 agent_reward \quad (41)$$

式中: C_i 表示第 i 个智能体的位置; β_5 和 β_6 是平衡与其他智能体距离奖励和碰撞奖励的参数, 分别为 0.001 和 10

$$agent_reward = \begin{cases} -100 & \text{发生碰撞} \\ 0 & \text{不发生碰撞} \end{cases} \quad (42)$$

当智能体到达目标点时, 会给予更大的正奖励, 此时整个路径规划结束。因此, 综合奖励函数表示为

$$R = \begin{cases} 500 & \text{路径规划结束} \\ R_1 + R_2 + R_3 + R_4 & \text{路径规划未结束} \end{cases} \quad (43)$$

为验证所提出奖励函数的有效性, 分别禁用了障碍物奖励、风流奖励、碰撞奖励来进行消融实验, 如图7所示。结果显示, 在综合考虑所有奖励因素的情况下, 获得了最高的平均奖励, 且碰撞次数仅为 0.18 , 路径复杂度也维持在较低的水平。表明所提出的奖励函数能够在兼顾路径效率、安全性和复杂度的同时, 显著提升整体性能。




图7 奖励消融实验

Fig.7 Reward ablation experiment

4.1 障碍数实验

智能体在进行路径规划的过程中, 障碍物对于规划路径的长度和移动方向起着决定性的作用, 其中障碍物的数量是一个重要的因素。无人机路径规划的本质是避开障碍物, 尽快到达目标点。为了实现这一目标, 智能体在风流的影响下大致向目标点移动, 并在接近障碍物时及时躲避。本文在 $4, 8, 16, 32$ 不同的建筑物数量环境下进行实验, 发现智能体可以完全避开这些建筑物并到达指定的终点, 如图8所示。




图8 不同建筑物数量的路径规划

Fig.8 Path planning with different numbers of buildings

为了显示 NP-MTDDQN 算法的性能,将 NP-MTDDQN 算法与 DQN 和 DDQN 算法在训练过程中的奖励变化进行了比较。如图 9 所示, NP-

MTDDQN 的奖励逐渐增加,直至保持稳定,根据收缩映射定理可以证明算法收敛到一个唯一的最优值。




图9 不同建筑物数量下DQN、DDQN、NP-MTDDQN的奖励收敛

Fig.9 Reward convergence of DQN, DDQN and NP-MTDDQN with different numbers of buildings

当建筑物数量由4增加至32时, NP-MTD-DQN的奖励收敛一直趋于稳定, 且收敛速度明显快于其他两种算法。由于DQN和DDQN使用统一的经验回放机制, 只考虑一步信息, 因此学习效率较低。DQN总是选择最大的 Q 值, 导致训练过程中会产生震荡。虽然DDQN缓解了DQN的高估问题, 但由于仍采用统一的经验回放机制, 只考虑一步信息, 所以训练曲线存在波动, 最终策略也为非全局最优。NP-MTDDQN具有明显的优势, 其 N 步更新和改进后的PER机制加速了收敛, 对最优策略的学习具有重要的指导作用。

4.2 优先障碍实验

城市当中有不同类型的建筑物, 包括具有重要意义且易受到破坏和储存易燃易爆设施的建筑物, 无人机若与之发生碰撞会对城市空间造成破坏, 无人机在进行路径规划的过程中需要优先考虑躲避这些建筑物。针对这一问题, 进行了优先

避障实验, 让智能体优先避开这类建筑物, 尽可能减少经济损失, 确保城市安全。在包含32个建筑物的环境中, 为其中8个建筑物设置较高的负奖励, 以体现建筑物优先级的区分。智能体在遇到高优先级建筑物时会收到较高的负奖励值, 因此智能体会优先避开奖励较低的建筑物, 通过权衡不同建筑物的奖励值来实现优先避障。分为四组不同的情况进行实验, 根据建筑物的位置划分出优先级较高的部分建筑物, 分别位于右上方、左下方、中间和随机位置。如图10所示, 其中红色体块表示高优先级建筑物, 灰色体块表示低优先级建筑物。从实验结果可以看出, 在四种情况下, 智能体可以避开所有的高优先级建筑物, 且高优先级建筑物在位于右上、左下以及随机的情况下, 智能体能够远离高优先级建筑物进行路径规划, 避免对高优先级建筑物造成破坏; 在高优先级建筑物位于中间的情况下, 大部分智能体也能够选择远离高优先级建筑物的路径。





图10 有高优先级建筑物的路径规划


Fig.10 Path planning with high-priority buildings

本组实验的奖励收敛对比如图11所示。在这组实验中,DQN和DDQN算法的整体性能较差,NP-MTDDQN算法的奖励收敛效果明显优于DDQN和DQN。DQN由于高估问题严重影响了训练结果。此外,由于DQN采用均匀经验回放,积极经验在训练过程中无法得到充分的利用,因此其性能较不稳定。DQN和DDQN的收敛速度


远低于NP-MTDDQN,且奖励收敛曲线波动较大,在存在优先级建筑物的情况下难以快速收敛。可见 N 步更新和改进后的PER机制对于加快算法收敛速度具有重要意义。从这组实验来看,当存在不同优先级的建筑物时,NP-MTDDQN可以充分发挥其作用,解决DQN和DDQN性能差的问题。




(a)高优先级建筑物位于右上



(b)高优先级建筑物位于左上



(c)高优先级建筑物位于中间



(d)高优先级建筑物位置随机

图11 有高优先级建筑物下DQN、DDQN、NP-MTDDQN的奖励收敛

Fig.11 Reward convergence of DQN, DDQN and NP-MTDDQN with high-priority buildings

4.3 动态障碍实验

前文提及的实验只考虑了建筑物对于无人机路径规划的影响,但在实际环境中可能存在不固定或实时移动的障碍物。如果直接将算法应用到城市空间中,很可能会使无人机产生错误的路径,与障碍物相撞。因此,本文进行了动态避障实验,在32个建筑物的基础上,分别增加了4个动态障碍物和8个动态障碍物进行测试,其中绿色方块表示动态障碍物。在这种情况下,动态障碍物的位置在每一个时间步都是变化的。4个动态障碍物和8个动态障碍物在不同时间步的测试结果如图12所示,可以看出障碍物的运动有很大的不同,智能体最终规划的路线成功避开了所有障碍物。


DQN、DDQN与NP-MTDDQN的奖励收敛对

比如图13所示。在存在动态障碍物的情况下,由于智能体探索的积极经验样本较少,基于DQN和DDQN的智能体在训练过程中很难探索到最优路径,因此DQN和DDQN很难收敛。而NP-MTDDQN算法由于 N 步更新和改进后的PER机制而获得了更好的性能,使得该算法在具有动态障碍物的环境中具有一定的适应性。


从以上三组实验结果来看,NP-MTDDQN算法在低空环境下进行路径规划的表现良好,可以在具有不同类型障碍物的环境中找到最优路径。特别是在具有不同优先级障碍物、动态障碍物的环境中能够寻找到达目标点的最优路径,满足了实际低空环境的动态性和实时性需求。在前文进行的实验中,智能体可以在没有经验的情况下从零开始学习,通过自主决策逐渐避开障碍物,到达

目标点,充分展现了路径规划的自主性,为无人机


在低空环境中的广泛应用提供了一种新的方法。




(a) 动态障碍物数量为4时的初始环境



(b) 动态障碍物数量为4时的最终环境




(c) 动态障碍物数量为8时的初始环境




(d) 动态障碍物数量为8时的最终环境

图12 有动态障碍物下的路径规划

Fig.12 Path planning with dynamic obstacles



(a) 动态障碍物数为4时



(b) 动态障碍物数为8时

图13 有动态障碍物下DQN、DDQN、NP-MTDDQN的奖励收敛

Fig.13 Reward convergence of DQN, DDQN and NP-MTDDQN with dynamic obstacles

为进一步展示算法的性能,与A*、RRT算法进行了对比实验,表2展示了三种算法在不同环境下的路径规划长度。A*算法具有经典的启发式搜索特性,其性能在简单环境下表现良好,但随着环境复杂度的提高,其规划路径长度不断增加,且在动态环境中适应能力较弱。RRT算法搜寻路径的随


机性导致其路径长度具有较大波动,且在高复杂度环境下往往冗长。相比之下,NP-MTDDQN算法通过强化学习的全局优化能力,实现了在不同环境下路径长度的显著缩短。实验结果进一步验证了NP-MTDDQN算法在路径规划方面的显著优势,尤其在复杂的动态环境中,其表现更具鲁棒性

和实用价值,为路径规划问题的研究和应用提供了新的解决方案。


表2 A*、RRT、NP-MTDDQN算法路径长度对比
Tab.2 Comparison of path lengths for A*, RRT and NP-MTDDQN algorithms

测试环境	不同算法的路径长度/m		
	A*	RRT	NP-MTDDQN
建筑物数量:4	13 015.29	14 115.22	12 008.91
建筑物数量:8	13 635.47	14 218.36	12 067.19
建筑物数量:16	14 687.25	15 073.67	12 183.78
建筑物数量:32	15 495.34	17 261.23	12 266.55
建筑物数量:32 优先级建筑物分布:随机	—	—	12 916.20
建筑物数量:32 动态障碍物数量:4	—	—	12 375.97

为验证所提算法的普适性,选取西安市雁塔区和昆明市呈贡区作为新的实验区域,利用其风流数据构建了两个具有不同风场的环境,使用NP-MTDDQN算法进行路径规划,并记录了各自的奖励收敛情况,如图14和图15所示。实验结果表明,该算法在不同的城市环境下均能找到最优路径,实现在不同风流环境下的多无人机协同作业。在奖励收敛方面,由于西安市雁塔区的风向为东北风,与智能体路径规划的整体方向大致相同,且风速(1.8 m/s)较小,因此其奖励收敛速度较快,表现出较高的稳定性。而昆明市呈贡区的风向为西南风,与智能体路径规划方向存在较大偏差,且风速(3.6 m/s)较大,使得算法在初期训练阶段的收敛速度相对较慢,但经过长期训练后,奖励值逐渐稳定,表明算法能够适应复杂风流环境并调整路径规划策略。



(a) 西安市雁塔区风流环境下的路径规划



(b) 昆明市呈贡区风流环境下的路径规划

图14 西安市雁塔区与昆明市呈贡区风流环境下的路径规划

Fig.14 Path planning in wind flow environments of Yanta district, Xi'an and Chenggong district, Kunming




图15 西安市雁塔区与昆明市呈贡区风流环境下的奖励收敛

Fig.15 Reward convergence in wind flow environments of Yanta district, Xi'an and Chenggong district, Kunming

5 结束语

本文采用强化学习方法,有效解决了低空环境中存在多样建筑物和动态障碍物的多无人机路径规划难题。为贴近实际应用需求,依据山东省济南市市中区的实际风流数据,构建了一个涵盖多种建筑物类型和动态障碍物的低空环境,为算法验证提供了有力的环境支持。创新性地提出了NP-MTDDQN算法,以有效解决无人机在低空环境中的路径规划、动态避障及多机协同等核心挑战。实验结果显示,融合了 N 步更新策略和改进后的PER机制的NP-MTDDQN算法,在面对低空环境中复杂的高优先级建筑物和动态障碍物时,

均能找到最优路径。其性能表现优于DQN和DDQN算法,显著提升了无人机路径规划的效率与准确性,确保了无人机的安全自主飞行。随着低空经济的蓬勃兴起,NP-MTDDQN算法有望在低空智能交通网络构建及未来城市空中服务等领域大展拳脚,为低空经济时代下的智能交通网络建设提供坚实的技术支撑。

本文提出的NP-MTDDQN算法与深度强化学习技术相结合,为低空智能交通网络的构建提供了一种智能化的路径规划与避障方案。为了加速城市低空智能交通网络的构建,建议在城市关键区域布局低空起降平台和补给设施,以确保低空交通的高效顺畅运行;建议实施分层空域管理策略,构建基于三维网格的航线网络体系,并利用5G通信技术实现航线数据的精准管理。此外,建议积极发展基于物联网和6G网络的智能监控系统,以实现对低空空域内交通流量和路径规划的实时动态调整和优化,进而提升网络的适应性和整体运行效率。展望未来,低空智能交通网络有望提升城市的整体运行效率,优化紧急响应机制,为城市交通带来颠覆性的变革和发展。

参考文献

- [1] FAN L, WANG X, YANG J, et al. Social radars for social vision of intelligent vehicles: a new direction for vehicle research and development[J]. *IEEE Transactions on Intelligent Vehicles*, 2024, 9(3): 4244-4248.
- [2] YUN W J, JUNG S, KIM J, et al. Distributed deep reinforcement learning for autonomous aerial eVTOL mobility in drone taxi applications[J]. *ICT Express*, 2021, 7(1): 1-4.
- [3] KIM S, KIM T, SUH K, et al. Energy and environmental performance of a passenger drone for an urban air mobility (UAM) policy with 3D spatial information in Seoul[J]. *Journal of Cleaner Production*, 2023, 415: 137683.
- [4] GUAN X, SHI H, XU D, et al. The exploration and practice of low-altitude airspace flight service and traffic management in China[J]. *Green Energy and Intelligent Transportation*, 2024, 3(2): 100149.
- [5] DECKER C, CHIAMBARETTO P. Economic policy choices and trade-offs for Unmanned aircraft systems Traffic Management (UTM): Insights from Europe and the United States[J]. *Transportation Research Part A: Policy and Practice*, 2022, 157: 40-58.
- [6] MCCARTHY T, PFORTE L, BURKE R. Fundamental elements of an urban UTM[J]. *Aerospace*, 2020, 7(7): 85.
- [7] SAFADI Y, FU R, QUAN Q, et al. Macroscopic fundamental diagrams for low-altitude air city transport[J]. *Transportation Research Part C: Emerging Technologies*, 2023, 152: 104141.
- [8] QU W, XU C, TAN X, et al. Preliminary concept of urban air mobility traffic rules[J]. *Drones*, 2023, 7(1): 54.
- [9] HUANG C, FANG S, WU H, et al. Low-altitude intelligent transportation: System architecture, infrastructure, and key technologies[J]. *Journal of Industrial Information Integration*, 2024, 42: 100694.
- [10] GUO J, CHEN L, LI L, et al. Advanced air mobility: an innovation for future diversified transportation and society[J]. *IEEE Transactions on Intelligent Vehicles*, 2024, 9(2): 3106-3110.
- [11] 刘泉, 陈瑶瑶, 洪晓苇, 等. 面向无人机的城市低空空域规划的国际经验[J]. *城市规划学刊*, 2024(5): 64-70.
LIU Quan, CHEN Yaoyao, HONG Xiaowei, et al. International experience of urban low altitude airspace planning for drones[J]. *Urban Planning Forum*, 2024(5): 64-70.
- [12] KIM M S, HONG W H, LEE Y H, et al. Selection of take-off and landing sites for firefighter drones in urban areas using a GIS-based multi-criteria model[J]. *Drones*, 2022, 6(12): 412.
- [13] LI X, TUPAYACHI J, SHARMIN A, et al. Drone-aided delivery methods, challenge, and the future: a methodological review[J]. *Drones*, 2023, 7(3): 191.
- [14] MOSHREF-JAVADI M, WINKENBACH M. Applications and Research avenues for drone-based models in logistics: a classification and review[J]. *Expert Systems with Applications*, 2021, 177: 114854.
- [15] AL-RUBAYE S, TSOURDOS A, NAMUDURI K. Advanced air mobility operation and infrastructure for sustainable connected eVTOL vehicle[J]. *Drones*, 2023, 7(5): 319.
- [16] KELLER A, BEN-MOSHE B. A robust and accurate landing methodology for drones on moving targets[J]. *Drones*, 2022, 6(4): 98.
- [17] STÖCKER C, BENNETT R, NEX F, et al. Review of the current state of UAV regulations[J]. *Remote Sensing*, 2017, 9(5): 459.

- [18] TRAN T H, NGUYEN D D. Management and regulation of drone operation in urban environment: a case study[J]. *Social Sciences*, 2022, 11(10): 474.
- [19] ALAMOURI A, LAMPERT A, GERKE M. An exploratory investigation of UAS regulations in Europe and the impact on effective use and economic potential[J]. *Drones*, 2021, 5(3): 63.
- [20] SOUANEF T, AL-RUBAYE S, TSOURDOS A, et al. Digital twin development for the airspace of the future [J]. *Drones*, 2023, 7(7): 484.
- [21] 刘洁敏, 苏雪娇, 沈振江. 无人机交通治理导向的城市低空空域与地上地下空间协同开发模式探析[J/OL]. *国际城市规划*; 1-16. (2024-08-09)[2024-11-04] <https://doi.org/10.19830/j.upi.2024.236>.
- LIU Jiemin, SU Xuejiao, SHEN Zhenjiang. Exploring the collaborative development model of urban low-altitude airspace and surface-subsurface spaces oriented by UAV-based traffic governance[J/OL]. *Urban Planning International*: 1-16.(2024-08-09)[2024-11-04] <https://doi.org/10.19830/j.upi.2024.236>
- [22] 谢华, 韩斯特, 尹嘉男, 等. 城市低空无人机飞行计划协同推演与优化调配方法[J]. *航空学报*, 2024, 45(19): 269-291.
- XIE H, HAN S T, YIN J N, et al. Cooperative deduction and optimal allocation method for urban low-altitude UAV flight plan[J]. *Acta Aeronautica et Astronautica Sinica*, 2024, 45(19): 269-291.
- [23] ALAMOUDI O, AL-HASHIMI M. On the energy behaviors of the bellman - ford and dijkstra algorithms: a detailed empirical study[J]. *Journal of Sensor and Actuator Networks*, 2024, 13(5): 67.
- [24] WANG H, LOU S, JING J, et al. The EBS-A* algorithm: an improved A* algorithm for path planning[J]. *PLoS One*, 2022, 17(2): e0263841.
- [25] SZCZEPANSKI R, BEREIT A, TARCZEWSKI T. Efficient local path planning algorithm using artificial potential field supported by augmented reality[J]. *Energies*, 2021, 14(20): 6642.
- [26] WU Z, MENG Z, ZHAO W, et al. Fast-RRT: a RRT-based optimal path finding method[J]. *Applied Sciences*, 2021, 11(24): 11777.
- [27] DARESTANI M Z, LIU J Y, HECKEL R. Test-Time training can close the natural distribution shift performance gap in deep learning based compressed sensing [DB / OL]. (2022-04-14) [2024-12-06]. <https://doi.org/10.48550/arXiv.2204.07204>.
- [28] SHAN D, ZHANG S, WANG X, et al. Path-planning strategy: adaptive ant colony optimization combined with an enhanced dynamic window approach[J]. *Electronics*, 2024, 13(5): 825.
- [29] ALKAFWEEN E, HASSANAT A, ESSA E, et al. An efficiency boost for genetic algorithms: initializing the GA with the iterative approximate method for optimizing the traveling salesman problem—experimental insights[J]. *Applied Sciences*, 2024, 14(8): 3151.
- [30] 黄琰, 张锦. 基于深度强化学习的车辆路径问题求解方法[J]. *交通运输工程与信息学报*, 2022, 20(3): 114-127.
- HUANG Yan, ZHANG Jin. Solving vehicle routing problem using deep reinforcement learning[J]. *Journal of Transportation Engineering and Information*, 2022, 20 (3): 114-127.
- [31] YAN C, XIANG X, WANG C. Towards real-time path planning through deep reinforcement learning for a UAV in dynamic environments[J]. *Journal of Intelligent & Robotic Systems*, 2020, 98(2): 297-309.
- [32] YAN N, HUANG S B, KONG C. Reinforcement learning-based autonomous navigation and obstacle avoidance for USVs under partially observable conditions[J]. *Mathematical Problems in Engineering*, 2021, 2021(1): 5519033.
- [33] YANG Y, LI J T, PENG L L. Multi-robot path planning based on a deep reinforcement learning DQN algorithm [J]. *CAAI Transactions on Intelligence Technology*, 2020, 5(3): 177-183.
- [34] HAN H, WANG J, KUANG L, et al. Improved robot path planning method based on deep reinforcement learning[J]. *Sensors*, 2023, 23(12): 5622.
- [35] DEGUALE D A, YU L, SINISHAW M L, et al. Enhancing stability and performance in mobile robot path planning with PMR-dueling DQN algorithm[J]. *Sensors*, 2024, 24(5): 1523.
- [36] KONG F, WANG Q, GAO S, et al. B-APFDQN: a UAV path planning algorithm based on deep Q-network and artificial potential field[J]. *IEEE Access*, 2023, 11: 44051-44064.
- [37] HUANG R, QIN C, LI J L, et al. Path planning of mobile robot in unknown dynamic continuous environment

- using reward-modified deep Q-network[J]. *Optimal Control Applications and Methods*, 2023, 44(3): 1570-1587.
- [38] SHEN Q, ZHANG D, HE Q, et al. A novel multi-objective dung beetle optimizer for Multi-UAV cooperative path planning[J]. *Heliyon*, 2024, 10(17): e37286.
- [39] 凌帅, 杨娟, 孙鹏, 等. 多目标协同下的即时配送路径优化[J/OL]. *交通运输工程与信息学报*: 1-24 (2024-09-30) [2024-12-20]. <https://doi.org/10.19961/j.cnki.1672-4747.2024.06.008>.
- LING Shuai, YANG Juan, SUN Peng, et al. The multi-objective instant delivery routing problem considering the labor rights and safety[J/OL]. *Journal of Transportation Engineering and Information*: 1-24 (2024-09-30) [2024-12-20]. <https://doi.org/10.19961/j.cnki.1672-4747.2024.06.008>.
- [40] ZHANG X, XIA S, LI X, et al. Multi-objective particle swarm optimization with multi-mode collaboration based on reinforcement learning for path planning of unmanned air vehicles[J]. *Knowledge-Based Systems*, 2022, 250: 109075.
- [41] 王娜, 马利民, 姜云春, 等. 基于多 Agent 深度强化学习的无人机协作规划方法[J]. *计算机应用与软件*, 2024, 41(9): 83-89, 96.
- WANG Na, MA Limin, JIANG Yunchun, et al. A UAV cooperative planning method based on Multi-Agent deep reinforcement learning[J]. *Computer Applications and Software*, 2024, 41(9): 83-89, 96.
- [42] 张子贤, 关伟, 奇格奇. 基于多智能体元强化学习的危险品运输路径优化[J]. *交通运输工程与信息学报*, 2024, 22(3): 93-106.
- ZHANG Zixian, GUAN Wei, QI Geqi. Optimization method for hazardous freight transportation routes based on multi-agent meta-reinforcement learning[J]. *Journal of Transportation Engineering and Information*, 2024, 22(3): 93-106.
- [43] CHEN Y, DONG Q, SHANG X, et al. Multi-UAV autonomous path planning in reconnaissance missions considering incomplete information: a reinforcement learning method[J]. *Drones*, 2022, 7(1): 10.

(责任编辑: 刘娉婷)